

CHAPITRE 2 REVUE DE LITTÉRATURE

Cette revue de littérature présente une analyse de l'état de l'art pour la génération de trajectoires robotisées sûres en environnement quasi-statique et non structuré. Elle est organisée selon l'architecture en chaîne « perception, planification, action » proposée dans ce travail. Nous abordons d'abord les méthodes de génération de mouvement, en situant l'émergence du *Flow Matching* conditionnel retenu comme planificateur nominal. Ensuite, nous examinons les techniques de perception visuelle et de mémoire spatiale qui fournissent le conditionnement géométrique nécessaire. Les représentations géométriques permettant d'évaluer les collisions en temps réel sont ensuite analysées, suivies par les lois de commande sécuritaires réactives fondées sur la théorie du contrôle. Enfin, nous étudions les stratégies de couplage entre modèles génératifs et filtres de sécurité, ce qui prépare le positionnement de l'architecture découplée proposée dans ce mémoire.

2.1 Génération de trajectoires robotisées

Objectif de la section : Analyser le développement théorique et les limites connues des méthodes de génération de mouvements afin de situer le choix du *Flow Matching* conditionnel comme planificateur d'intention nominale.

2.1.1 Planification classique par échantillonnage et optimisation

La génération de mouvements sans collision a d'abord été abordée par des algorithmes déterministes raisonnant directement dans l'espace des configurations sans apprentissage préalable. Historiquement, deux grandes familles se dégagent selon qu'elles explorent cet espace par tirages aléatoires ou qu'elles raffinent une trajectoire par optimisation continue. D'une part, les méthodes par échantillonnage, à l'instar de l'algorithme *Rapidly-exploring Random Tree star* (RRT*) de Karaman et Frazzoli [1], construisent incrémentalement un arbre de configurations valides. Bien que ces planificateurs, largement implémentés au sein de la bibliothèque *Open Motion Planning Library* (OMPL) [2], garantissent une complétude probabiliste, voire une optimalité asymptotique pour les variantes étoilées comme RRT*, ils produisent généralement des trajectoires géométriquement rugueuses et saccadées. Ce défaut impose une étape de lissage a posteriori qui dépend fortement de la complexité géométrique de la scène [3].

D'autre part, les approches par optimisation locale adoptent une démarche inverse en raffinant une trajectoire initiale par minimisation d'une fonctionnelle de coût. Par exemple,

CHOMP (*Covariant Hamiltonian Optimization for Motion Planning*) [4] exploite le gradient d'un champ de distance signé pré-calculé pour repousser la trajectoire d'initialisation (typiquement une interpolation rectiligne dans l'espace des configurations) hors des obstacles tout en la lissant. De même, TrajOpt [5] formule le problème sous forme d'une séquence d'optimisations convexes sous contraintes relaxées de non-collision, démontrant d'excellents taux de réussite sur des bras articulés complexes. Néanmoins, ces méthodes restent intrinsèquement sensibles à la trajectoire d'initialisation et tendent à converger vers des minima locaux sous-optimaux, ce qui peut conduire à des violations de contraintes si le champ de distance est bruité. Pour pallier cette dépendance à l'initialisation, les approches classiques d'amorçage (*warm-starting*) proposent d'utiliser des heuristiques géométriques ou des chemins sans collision issus d'algorithmes par échantillonnage, comme RRT-Connect [6] ou des cartes routières probabilistes (PRM) [7], pour ensemençer l'optimiseur. Ce couplage hybride échantillonnage-optimisation combine la complétude globale du premier et la régularité locale du second. L'évolution de ces stratégies classiques d'amorçage vers des représentations apprises assure une transition naturelle vers les méthodes fondées sur l'apprentissage, qui cherchent à s'affranchir de la recherche géométrique explicite en exploitant des démonstrations expertes.

2.1.2 Apprentissage par démonstration, clonage de comportement et renforcement

L'apprentissage par démonstration (*Learning from Demonstration*, LfD), dont les fondations théoriques ont été posées par Atkeson et Schaal [8,9] en 1997 et 1999, avant d'être synthétisées par Argall et al. [10] en 2009, vise à reproduire un comportement expert sans programmer explicitement la loi de commande. La formulation la plus directe, le clonage de comportement (*Behavior Cloning*, BC), dont le concept remonte aux travaux pionniers d'ALVINN de Pomerleau [11] et a été formalisé par Bain et Sammut [12], traite le problème comme une régression supervisée des actions expertes à partir des observations. Bien qu'appliqué avec succès à des tâches d'acquisition alimentaire par imitation visuelle ou de manipulation fine moderne [13–15], le BC sous perte quadratique (*Mean Squared Error*, MSE) souffre de deux limites structurelles majeures : l'erreur cumulative (*compounding errors*), où de petites déviations entraînent le robot hors de la distribution d'entraînement, et l'effondrement de la multimodalité, la moyenne de démonstrations divergentes produisant des actions aberrantes ou invalides.

Pour surmonter ces écueils, Florence et al. [17] ont introduit le clonage de comportement implicite (*Implicit BC*) représentant la politique par un modèle d'énergie. Cette formulation




Figure 2.1 Représentation d’une trajectoire obtenue par *Behavior Cloning* hors distribution, tirée de [16]

permet de capturer des distributions d’actions multivaluées et discontinues, surpassant la régression directe sur des tâches nécessitant une grande précision géométrique. Par ailleurs, des travaux connexes étendent cette logique à l’imitation strictement hors ligne [18] ou exploitent des représentations auto-supervisées pour accroître la généralisation du système [19]. En parallèle, l’apprentissage par renforcement (*Reinforcement Learning*, RL) résout le problème de la multimodalité par exploration active de l’environnement [20,21]. Toutefois, le RL se heurte à une inefficacité d’échantillonnage prohibitive et pose des risques majeurs de collision, ce qui complique son déploiement direct sur des plateformes physiques réelles. Enfin, une approche alternative consiste à encoder le mouvement sous forme de systèmes dynamiques stables par construction (tels que l’estimateur SEDS [22]) afin de garantir la convergence vers la cible, bien que cela se fasse au détriment de l’expressivité par rapport aux modèles génératifs récents.

2.1.3 Modèles génératifs, politiques de diffusion et Flow Matching

Les politiques génératives modélisent explicitement la distribution des trajectoires expertes, ce qui leur permet de représenter naturellement la multimodalité inhérente aux comportements humains [23, 24]. Récemment, la *Diffusion Policy* de Chi et al. [25], inspirée des modèles probabilistes de débruitage (*Denoising Diffusion Probabilistic Models*) [26] et de la planification générative [27, 28], a démontré des performances remarquables en manipulant des objets par un processus de débruitage stochastique itératif. De même, sa variante tridimensionnelle (*3D Diffusion Policy*) conditionne cette génération sur un nuage de points [29], renforçant la robustesse géométrique. Toutefois, le principal inconvénient des politiques de

diffusion réside dans leur latence d'inférence élevée : la génération d'une trajectoire requiert de nombreuses évaluations séquentielles du réseau de neurones, limitant leur application en boucle fermée à haute fréquence. Bien que des techniques de distillation de modèle (telles que ManiCM [30] ou d'autres approches accélérées [31, 32]) parviennent à ramener l'inférence à une seule étape, elles nécessitent des phases d'entraînement complexes et peuvent dégrader la stabilité des trajectoires générées.

Pour offrir une alternative déterministe plus directe et efficace, Lipman et al. [33] ont introduit le formalisme du *Flow Matching*. L'objectif est d'apprendre un champ de vecteurs $v_\theta(\mathbf{x}, t)$, indexé par un temps de flux $t \in [0, 1]$, qui déplace continûment un échantillon initial issu d'une distribution simple $p_0(\mathbf{x})$ (typiquement une gaussienne standard $\mathcal{N}(\mathbf{0}, \mathbf{I})$) vers la distribution cible des trajectoires expertes $p_1(\mathbf{x})$. Une trajectoire candidate $\mathbf{x}_t$ est générée en intégrant l'équation différentielle ordinaire (ODE) associée :

$$\frac{d\mathbf{x}_t}{dt} = v_\theta(\mathbf{x}_t, t). \quad (2.1)$$

Le champ de vecteurs marginal engendrant la distribution de probabilité $p_t(\mathbf{x})$ étant généralement incalculable analytiquement, le *Conditional Flow Matching* (CFM) [34] résout ce problème en définissant un chemin de probabilité conditionnel $p_t(\mathbf{x} \mid \mathbf{x}_0, \mathbf{x}_1) = \mathcal{N}(\mathbf{x} \mid \mu_t(\mathbf{x}_0, \mathbf{x}_1), \sigma_t^2 \mathbf{I})$ et son champ de vecteurs associé $u_t(\mathbf{x} \mid \mathbf{x}_0, \mathbf{x}_1)$ qui sont analytiquement traitables. Pour des distributions gaussiennes conditionnelles, ce champ cible s'exprime par :

$$u_t(\mathbf{x} \mid \mathbf{x}_0, \mathbf{x}_1) = \frac{\dot{\sigma}_t}{\sigma_t} (\mathbf{x} - \mu_t(\mathbf{x}_0, \mathbf{x}_1)) + \dot{\mu}_t(\mathbf{x}_0, \mathbf{x}_1), \quad (2.2)$$

où $\dot{\mu}_t$ et $\dot{\sigma}_t$ désignent les dérivées temporelles des paramètres du chemin. Le réseau de neurones v_θ est alors entraîné en minimisant la perte de régression du champ de vecteurs conditionnel :

$$\mathcal{L}(\theta) = \mathbb{E}_{t \sim \mathcal{U}[0,1], \mathbf{x}_1 \sim p_1, \mathbf{x}_0 \sim p_0, \mathbf{x}_t \sim p_t(\cdot \mid \mathbf{x}_0, \mathbf{x}_1)} \left[\left\| v_\theta(\mathbf{x}_t, t) - u_t(\mathbf{x}_t \mid \mathbf{x}_0, \mathbf{x}_1) \right\|^2 \right]. \quad (2.3)$$

Dans le cadre du *Rectified Flow* proposé par Liu et al. [35], le chemin est défini par interpolation linéaire simple entre le bruit et la donnée réelle, avec une variance constante :

$$\mu_t(\mathbf{x}_0, \mathbf{x}_1) = t\mathbf{x}_1 + (1-t)\mathbf{x}_0, \quad \sigma_t = \sigma_{\min}, \quad (2.4)$$

ce qui réduit le champ cible u_t au vecteur constant reliant le point initial au point final :

$$u_t(\mathbf{x}_t \mid \mathbf{x}_0, \mathbf{x}_1) = \mathbf{x}_1 - \mathbf{x}_0. \quad (2.5)$$

Cette formulation linéaire favorise des trajectoires d'intégration quasi rectilignes, permettant d'intégrer l'ODE en un nombre réduit d'étapes de discrétisation tout en préservant la qualité des trajectoires. Pour adapter ce formalisme à la robotique, il suffit de conditionner le champ $v_\theta(\mathbf{x}, t \mid \mathbf{o})$ sur une observation sémantique ou géométrique $\mathbf{o}$ (comme un nuage de points), ce qui permet d'obtenir un planificateur de trajectoire réactif, comme l'illustre le framework PointFlowMatch [36].

Plus récemment, de nombreuses extensions ont cherché à accroître l'efficacité et la généralisation géométrique de ces modèles. Des approches telles que ManiFlow [37], MeanFlow [38, 39] et les politiques à flux continu [40] visent la génération de mouvements en une ou deux étapes d'inférence. D'autres travaux, à l'instar de FlowMP [41, 42], étendent le *Flow Matching* aux dynamiques du second ordre afin de générer des trajectoires respectant les contraintes d'accélération et de couple. Enfin, la politique riemannienne (*Riemannian Flow Matching Policy*, RFMP) de Braun et al. [43] transpose ce formalisme directement sur des variétés non euclidiennes telles que $SE(3)$ par interpolation géodésique, réduisant les saccades de rotation et le temps de calcul. Cette combinaison unique d'expressivité multimodale, de rapidité d'intégration déterministe et de robustesse géométrique justifie l'adoption du *Flow Matching* comme planificateur nominal d'intention au sein de notre architecture.




Figure 2.2 Représentation du champ de vitesse u_t transportant la distribution initiale p_0 vers la distribution cible p_1 pour $t \in [0, 1]$, tirée de [44]

2.2 Perception visuelle et mémoire spatiale

Objectif de la section : Documenter les mécanismes permettant de convertir un flux de données visuelles bidimensionnelles et bruitées en un signal de conditionnement géométrique statique et persistant.

2.2.1 Vision-langage, segmentation zéro-shot et suivi visuel

La première étape de l'architecture consiste à extraire de la scène l'objet pertinent pour la tâche et à l'ancrer sémantiquement. Dans cette perspective, deux grands paradigmes s'oc-

cupent d’associer perception et action : les modèles monolithiques, qui fusionnent perception et action, et les architectures modulaires, qui séparent la compréhension sémantique de la génération de mouvement. D’une part, les architectures *Vision-Language-Action* (VLA) monolithiques intègrent la perception sémantique et le contrôle dans un unique réseau de neurones entraîné de bout en bout. Des modèles tels que RT-2 de Brohan et al. [45] ou *OpenVLA* de Kim et al. [46] en sont particulièrement représentatifs. Ce dernier, fort de sept milliards de paramètres, surpasse significativement les modèles propriétaires antérieurs sur une grande variété de tâches de manipulation [47, 48]. Néanmoins, leur principale limite réside dans leur latence d’inférence élevée, peu compatible avec un contrôle réactif en temps réel. Bien que des versions compressées comme TinyVLA [49] tentent d’accélérer ce processus, le temps de calcul reste un verrou majeur.

D’autre part, les approches modulaires découplent l’exécution en confiant l’interprétation sémantique de l’invite textuelle (par exemple, identifier l’aliment à acquérir) à un modèle de vision-langage ou à un grand modèle de langage (LLM) [50–53], laissant la localisation géométrique fine à des modules dédiés. Ce découplage préserve l’interprétabilité du système et permet de remplacer indépendamment chaque composant. Pour la segmentation fine des objets, le modèle fondateur *Segment Anything* (SAM) de Kirillov et al. [54], sorti en 2023, a démontré d’excellentes capacités de généralisation zéro-shot sans réentraînement. Plus récemment, en 2025, sa troisième version (*Segment Anything 3* ou SAM3) [55] a introduit la segmentation par concept, permettant de localiser toutes les instances correspondant à une requête sémantique en une seule inférence. Enfin, le modèle SAM2, sorti en 2024, de Ravi et al. [56] permet d’étendre cette logique dans le domaine temporel en assurant la propagation cohérente et le suivi des masques sémantiques le long du flux d’images, préparant ainsi la reconstruction 3D de la scène.

2.2.2 Reconstruction RGB-D et représentation par nuages de points

Une fois le masque sémantique obtenu en deux dimensions, la rétroprojection géométrique de ses pixels dans l’espace cartésien, facilitée par les caméras RGB-D, permet de générer des nuages de points tridimensionnels de la cible et des obstacles. Se pose alors la question de la représentation géométrique optimale pour conditionner les politiques génératives. À cet égard, le conditionnement direct sur des nuages de points s’est imposé comme une alternative solide aux images brutes, car il capture explicitement les relations spatiales tridimensionnelles de la scène [57, 58]. Cette efficacité est illustrée par la politique *3D Diffusion Policy* [29] et le modèle fondationnel FP3 [59], qui démontrent une excellente généralisation géométrique avec un nombre réduit de démonstrations expertes.

Toutefois, l’acquisition d’un nuage de points à partir d’une unique caméra embarquée reste vulnérable aux occlusions physiques induites par les mouvements de l’effecteur ou du bras articulé lui-même. Pour y faire face, des méthodes comme CordViP de Fu et al. [60] proposent de reconstruire les zones masquées en combinant proprioception et estimation de pose 6D, restaurant ainsi la géométrie de la zone d’interaction. Bien que certains travaux suggèrent que des approches bidimensionnelles enrichies en pseudo-3D puissent parfois suffire [61, 62], l’utilisation de nuages de points 3D bruts présente l’avantage de ne requérir aucun modèle CAO préalable des objets de la scène, ce qui s’avère indispensable pour manipuler des formes complexes ou non structurées.

2.2.3 Cartes persistantes face aux occlusions et pertes de détection

Néanmoins, la perception instantanée en direct est insuffisante lors de tâches robotiques interactives dans des environnements dynamiques. Dès que le robot effectue une approche, son propre corps engendre des occlusions physiques massives, masquant temporairement la cible ou les obstacles proches [63]. Une politique fonctionnant purement en boucle ouverte et sans mémoire spatiale serait alors incapable de maintenir sa consigne de mouvement. Pour résoudre cette limite, la cartographie d’environnements dynamiques propose d’intégrer des graphes de facteurs (à l’instar de DynoSAM [64]) afin de séparer la géométrie statique des trajectoires d’objets mobiles. De même, des approches probabilistes comme SE(3)-PoseFlow de Jin et al. [65] utilisent le *Flow Matching* pour estimer les distributions de poses sous forte occlusion.

Afin de stabiliser durablement le signal de conditionnement fourni au planificateur nominal, l’intégration d’une couche de mémoire spatiale persistante, telle qu’une grille de voxels locale ou une carte d’occupation historique, s’appuie classiquement sur des méthodes de cartographie par grille d’occupation [66, 67]. En accumulant et en filtrant les nuages de points capturés au fil du temps par fusion spatio-temporelle [68, 69], cette mémoire spatiale maintient une représentation géométrique tridimensionnelle fiable des obstacles et de la cible, même lors de pertes de détection visuelle. Ce mécanisme garantit la continuité géométrique du signal envoyé au planificateur, constituant une brique essentielle de l’architecture développée pour naviguer de manière sécuritaire dans les zones confinées.

2.3 Représentations géométriques pour la collision

Objectif de la section : Évaluer les méthodes de modélisation de l’encombrement spatial du robot et des obstacles pour formuler des métriques de distance différentiables.

2.3.1 Champs de distance de la scène et limites computationnelles

Imposer une contrainte d'évitement active suppose de disposer d'une métrique de distance différentiable entre le robot et les obstacles de son environnement. Une première famille de méthodes centre cette métrique sur la scène en discrétisant l'espace de travail. Les champs de distance signés euclidiens (*Euclidean Signed Distance Fields*, ESDF) encodent, en chaque point de l'espace, la distance à la surface de l'obstacle le plus proche. Formellement, le champ associe à un point $\mathbf{p} \in \mathbb{R}^3$ sa distance signée à la surface d'un obstacle $\mathcal{O} \subset \mathbb{R}^3$:

$$d(\mathbf{p}) = s_{\mathcal{O}}(\mathbf{p}) \min_{\mathbf{q} \in \partial\mathcal{O}} \|\mathbf{p} - \mathbf{q}\|_2, \quad s_{\mathcal{O}}(\mathbf{p}) = \begin{cases} -1, & \mathbf{p} \in \mathcal{O}, \\ +1, & \text{sinon,} \end{cases} \quad (2.6)$$

où la distance est ainsi comptée négativement à l'intérieur du volume de l'obstacle et positivement à l'extérieur, la frontière $\partial\mathcal{O}$ correspondant au niveau zéro $d(\mathbf{p}) = 0$. Un tel champ de distance théorique vérifie l'équation eikonale :

$$\|\nabla d(\mathbf{p})\|_2 = 1, \quad (2.7)$$

indiquant que le gradient du champ est unitaire et pointe dans la direction d'éloignement la plus rapide de l'obstacle, ce qui fournit directement la direction d'évitement.

Pour évaluer numériquement ce champ de distance de la scène en robotique, trois grands paradigmes coexistent :

1. **Le pré-calcul hors ligne (Offline)** : Pour des environnements statiques et connus, l'ESDF est échantillonné à l'avance sur une grille de voxels à partir du modèle CAO de la scène. Cette méthode, utilisée historiquement dans des planificateurs comme CHOMP [4], permet des requêtes de distance en temps constant $\mathcal{O}(1)$ lors de la planification, mais s'avère incapable de s'adapter au moindre changement d'environnement ou à l'apparition d'obstacles imprévus.
2. **La reconstruction en ligne par grilles volumétriques incrémentales (Online Grids)** : Les bibliothèques de cartographie en direct, à l'instar d'OctoMap [67], Voxblox [70] ou nvblox [71], maintiennent et mettent à jour incrémentalement l'ESDF à partir des flux de données de capteurs RGB-D. Pour accroître la rapidité ou la précision de ces grilles, des architectures optimisées comme FIESTA [72] (optimisant la vitesse de calcul pour la planification de drones) ou Voxfield [73] (qui exploite des TSDF non projectifs pour améliorer la fidélité de la distance) ont été développées. Bien que ces grilles s'adaptent aux scènes dynamiques et exploitent le parallélisme des GPU [74], leur coût de mise à jour tridimensionnelle demeure élevé et dépend

fortement de la résolution choisie, ce qui devient prohibitif à la fréquence d’une boucle de commande réactive.

3. **Les champs de distance neuronaux continus en ligne (Online Continual Neural SDF)** : Afin de s’affranchir de la discrétisation par grilles volumétriques, des approches de reconstruction continue en ligne, comme iSDF d’Ortiz et al. [75], entraînent en temps réel un réseau de neurones de coordonnées sur le flux sensoriel actif pour apprendre une représentation continue et différentiable de la scène. Ce concept s’inscrit dans la lignée des frameworks de SLAM implicite en temps réel tels qu’iMAP [76] et sa variante hiérarchique NICE-SLAM [77]. Cependant, ces modèles neuronaux souffrent d’une latence de convergence lors de changements rapides de la scène et de risques d’oubli catastrophique, ce qui complique leur intégration directe dans une boucle de contrôle sécuritaire à haute fréquence.

Ces limitations computationnelles partagées motivent le développement de représentations alternatives centrées sur le robot plutôt que sur la scène.

2.3.2 Primitives conservatives et modèles géométriques simplifiés

Pour contourner la lourdeur du calcul des champs de distance globaux de la scène, une seconde famille de méthodes choisit plutôt de simplifier la géométrie du robot lui-même. L’approche classique consiste à encapsuler les différents liens de la chaîne cinématique dans des volumes englobants simples, tels que des sphères ou des capsules, dont les tests de collision analytiques se parallélisent très efficacement sur GPU. La bibliothèque cuRobo de Sundaralingam et al. [78] exploite cette idée pour générer des mouvements sûrs en quelques dizaines de millisecondes, surpassant de plus d’un ordre de grandeur les solveurs classiques de l’état de l’art. Récemment, ces enveloppes ont été adaptées pour prendre en compte l’outil monté à l’effecteur en temps réel [79]. Néanmoins, le revers de cette approximation géométrique conservative est qu’elle tend à surestimer grandement l’encombrement réel du robot. Cette perte d’espace libre exploitable restreint la capacité du robot à évoluer dans des zones confinées, ce qui est problématique pour des tâches d’assistance physique comme l’alimentation.

2.3.3 Champs de distance signée du robot

Afin de concilier la précision géométrique et la rapidité de calcul, un changement de paradigme récent propose de déplacer le champ de distance de la scène vers le robot en modélisant directement la géométrie du bras articulé. Les champs de distance du robot (*Robot Distance Fields*, RDF), introduits par Li et al. [80], approchent la SDF de chaque lien du robot par des polynômes de Bernstein. Pour une coordonnée spatiale normalisée $\mathbf{u} = (u_1, u_2, u_3) \in [0, 1]^3$,

la distance signée associée à un lien l s'écrit comme un produit tensoriel 3D de la base polynomiale de Bernstein de degré n :

$$\bar{d}_l(\mathbf{u}) = \sum_{i=0}^n \sum_{j=0}^n \sum_{k=0}^n c_{ijk}^l B_{i,n}(u_1) B_{j,n}(u_2) B_{k,n}(u_3), \quad (2.8)$$

où les coefficients c_{ijk}^l , appris hors ligne à partir du modèle CAO, encodent précisément la forme géométrique tridimensionnelle du lien. Les polynômes de base de Bernstein de degré n sont définis analytiquement par :

$$B_{i,n}(u) = \binom{n}{i} u^i (1-u)^{n-i}. \quad (2.9)$$

Puisque la distance approchée $\bar{d}_l(\mathbf{u})$ est une fonction polynomiale, son gradient par rapport aux coordonnées spatiales s'obtient analytiquement sans nécessiter de coûteuses approximations par différences finies. En particulier, la dérivée d'un polynôme de base par rapport à la coordonnée normalisée u s'écrit simplement sous la forme :

$$\frac{d}{du} B_{i,n}(u) = n (B_{i-1,n-1}(u) - B_{i,n-1}(u)), \quad (2.10)$$

avec la convention que $B_{-1,n-1}(u) = 0$ et $B_{n,n-1}(u) = 0$. Cette propriété permet un calcul exact et instantané du gradient spatial sur GPU, pour une empreinte mémoire négligeable.

Contrairement aux représentations neuronales alternatives (telles que les *Neural SDF* [81]) qui souffrent de temps d'inférence plus élevés et d'un manque de régularité mathématique, l'approximation polynomiale de Bernstein fournit une structure différentiable et continue. Ses gradients pouvant être interrogés directement par rapport aux points de l'environnement, Govoni et al. [82] les ont exploités pour l'évitement réactif dans un cadre de commande de tâches. Toutefois, l'usage d'opérateurs de composition non lisses (comme le minimum discret sur les distances des différents liens ou le *soft-min* pour regrouper les contributions de l'environnement) implique que la fonction de distance globale du robot n'est pas strictement de classe $\mathcal{C}^2$, une limitation théorique dont il faut tenir compte lorsque cette distance est exploitée comme fonction barrière dans une loi de commande.

2.4 Sécurité réactive et fonctions de contrôle barrières

Objectif de la section : Analyser les lois de commande réactives issues de la théorie du contrôle afin d'imposer une contrainte de sécurité en vitesse sous certaines hypothèses.

2.4.1 Champs de potentiel et méthodes réactives classiques

La sécurité réactive consiste à modifier localement et en temps réel le mouvement du robot directement lors de son exécution sur la plateforme physique. Historiquement, la première formulation repose sur des forces virtuelles à travers la méthode des champs de potentiel artificiels (APF) introduite par Khatib [83]. Le principe est d'associer à la cible une force attractive et aux obstacles des forces répulsives. Bien que cette approche soit très légère en calcul et s'implémente facilement en ligne, elle souffre de limites théoriques majeures : l'absence de garanties de stabilité pour des dynamiques complexes, des oscillations à proximité des obstacles et un blocage fréquent dans des minima locaux induits par des géométries concaves. Néanmoins, le concept reste exploité dans des architectures génératives récentes pour guider des politiques d'imitation vers des trajectoires sûres [84].

2.4.2 Fonctions barrières de contrôle et invariance avant

Pour pallier l'absence de garanties formelles de sécurité des champs de potentiel, les fonctions barrières de contrôle (*Control Barrier Functions*, CBF), formalisées par Ames et al. [85] sur la base des certificats de barrière de Wieland et Allgöwer [86], offrent un cadre d'invariance rigoureux. Considérons un système dynamique non linéaire affine en contrôle de la forme :

$$\dot{\mathbf{x}} = f(\mathbf{x}) + g(\mathbf{x})\mathbf{u}, \quad (2.11)$$

où $\mathbf{x} \in \mathbb{R}^d$ désigne l'état et $\mathbf{u} \in \mathbb{R}^m$ l'action de commande. On définit un ensemble de sécurité $\mathcal{C}$ comme le sous-ensemble de l'espace d'état où une fonction scalaire continûment différentiable $h : \mathbb{R}^d \rightarrow \mathbb{R}$ reste positive :

$$\mathcal{C} = \{\mathbf{x} \in \mathbb{R}^d : h(\mathbf{x}) \geq 0\}, \quad (2.12)$$

la frontière $h(\mathbf{x}) = 0$ marquant le contact ou la limite de sécurité avec l'obstacle. L'ensemble $\mathcal{C}$ est dit invariant vers l'avant si toute trajectoire débutant dans $\mathcal{C}$ y demeure indéfiniment. En exploitant les dérivées de Lie $L_f h(\mathbf{x}) = \nabla h(\mathbf{x})^\top f(\mathbf{x})$ et $L_g h(\mathbf{x}) = \nabla h(\mathbf{x})^\top g(\mathbf{x})$, la fonction h est une fonction barrière de contrôle s'il existe une fonction α de classe $\mathcal{K}$, c'est-à-dire strictement croissante et nulle à l'origine, telle que, dans le cas général :

$$\sup_{\mathbf{u} \in \mathbb{R}^m} [L_f h(\mathbf{x}) + L_g h(\mathbf{x})\mathbf{u}] \geq -\alpha(h(\mathbf{x})). \quad (2.13)$$

Cette condition autorise la fonction barrière à décroître à l'approche de la frontière, mais à un taux borné par α , qui s'annule exactement sur celle-ci : la trajectoire ne peut donc

jamais quitter l'ensemble sûr $\mathcal{C}$. En pratique, la fonction α est le plus souvent choisie linéaire, $\alpha(h) = \kappa h$ avec un gain $\kappa > 0$ réglant l'agressivité du freinage près de la frontière, ce qui conduit à la condition d'invariance affine en la commande :

$$L_f h(\mathbf{x}) + L_g h(\mathbf{x})\mathbf{u} \geq -\kappa h(\mathbf{x}). \quad (2.14)$$

Lorsque le contrôle du robot s'effectue directement en vitesse articulaire (degré relatif un, où l'état correspond à la configuration articulaire $\mathbf{x} = \mathbf{q}$ et l'action à la vitesse $\mathbf{u} = \dot{\mathbf{q}}$), la dynamique se réduit à $\dot{\mathbf{q}} = \mathbf{u}$. La condition barrière (2.14) se simplifie alors sous la forme linéaire suivante :

$$\nabla h(\mathbf{q})^\top \dot{\mathbf{q}} \geq -\kappa h(\mathbf{q}). \quad (2.15)$$

Dans le cadre de l'évitement de collision articulé, la fonction barrière $h_i(\mathbf{q})$ associée à un point critique i du robot s'exprime directement à partir de la distance physique aux obstacles $d_{\text{robot},i}(\mathbf{q})$, évaluée via le modèle de Bernstein (SDF locale), minorée d'une marge de sécurité minimale d_{safe} :

$$h_i(\mathbf{q}) = d_{\text{robot},i}(\mathbf{q}) - d_{\text{safe}}. \quad (2.16)$$

La condition (2.15) étant affine par rapport aux vitesses articulaires $\dot{\mathbf{q}}$, elle peut s'intégrer sous forme de contraintes linéaires au sein d'un programme quadratique (QP-CBF) résolu à chaque cycle de commande [87] :

$$\dot{\mathbf{q}}^* = \arg \min_{\dot{\mathbf{q}}} \frac{1}{2} \|\dot{\mathbf{q}} - \dot{\mathbf{q}}_{\text{nom}}\|_2^2 \quad \text{s.c.} \quad \nabla h_i(\mathbf{q})^\top \dot{\mathbf{q}} \geq -\kappa h_i(\mathbf{q}), \quad \forall i \in \{1, \dots, N_c\}, \quad (2.17)$$

où $\dot{\mathbf{q}}_{\text{nom}}$ représente la consigne nominale et N_c désigne le nombre de contraintes actives (les points critiques les plus proches de l'environnement). Le programme quadratique (2.17) agit ainsi comme un filtre de sécurité réactif en projetant la vitesse nominale sur le demi-espace admissible le plus proche. Des extensions étendent cette formulation aux systèmes mécaniques de degré relatif deux (commande en couples ou accélérations) [88].

2.4.3 Filtres de sécurité prédictifs et méthodes d'atteignabilité

La projection QP-CBF n'est toutefois qu'une instance d'un concept plus large, celui du filtre de sécurité, dont Hsu et al. [89] proposent une vue unifiée : un module de supervision minimalement invasif qui surveille la commande nominale, quelle qu'en soit l'origine, et ne la modifie que lorsque la sécurité l'exige. Au-delà des CBF, deux autres familles dominent ce paradigme. D'une part, les filtres de sécurité prédictifs de Wabersich et Zeilinger [90] transposent la philosophie de la commande prédictive : à chaque cycle, un problème de

commande optimale est résolu sur un horizon fini afin de vérifier qu’il existe encore une trajectoire de repli ramenant le système vers un ensemble sûr terminal. Cette anticipation corrige la principale faiblesse structurelle des CBF, leur myopie : là où la contrainte barrière ne raisonne que sur la dérivée instantanée de h , le filtre prédictif détecte à l’avance les situations où les saturations d’actionneurs rendront la contrainte infaisable. D’autre part, les méthodes fondées sur l’atteignabilité de Hamilton-Jacobi calculent l’ensemble des états à partir desquels la collision devient inévitable, offrant les garanties les plus robustes face aux perturbations bornées [91].

Ces gains d’anticipation et de robustesse ont cependant un coût computationnel élevé : le filtre prédictif requiert la résolution en ligne d’un programme non convexe sur tout l’horizon ainsi qu’un modèle dynamique fiable, tandis que l’atteignabilité de Hamilton-Jacobi souffre de la malédiction de la dimension et reste difficilement applicable au-delà de quelques dimensions d’état sans approximation [91]. Pour un bras à sept degrés de liberté contraint par des milliers de points de nuage renouvelés à chaque cycle de perception, la projection QP-CBF demeure la seule de ces trois familles à s’exécuter à la fréquence de commande visée, au prix d’un raisonnement purement instantané.

2.4.4 Limites des CBF sous perception bruitée et contrôle discret

Néanmoins, les garanties d’invariance théorique établies en temps continu et sous l’hypothèse d’un modèle géométrique parfait se dégradent fortement lors de leur déploiement sur une plateforme physique réelle. En effet, trois facteurs limitent l’invariance absolue :

1. **La discrétisation temporelle :** La boucle de commande s’exécute à fréquence finie, ce qui peut provoquer des franchissements de la barrière entre deux pas de calcul. Cette limite a conduit au développement des formulations en temps discret (DT-CBF) de la condition barrière [92].
2. **Les saturations matérielles :** Les limites de vitesse et de couple des actionneurs restreignent le domaine d’admissibilité du QP. Si la contrainte CBF exige une accélération ou une vitesse supérieure aux capacités physiques du robot, le programme quadratique devient infaisable [93], compromettant la sécurité.
3. **Le bruit de perception et l’erreur d’interface :** Le calcul du gradient sur des nuages de points réels et bruités introduit des fluctuations dans les contraintes. De plus, le suivi de la consigne de vitesse $\dot{\mathbf{q}}^*$ par un contrôleur en position bas niveau engendre des retards et des dérives cinématiques.

Par conséquent, dans des applications réelles non structurées, la loi de commande CBF doit être traitée comme un filtre de sécurité pragmatique, plutôt que comme une garantie formelle

infaillible, ce qui justifie l'utilisation de marges de sécurité conservatives.

2.5 Couplage entre modèles génératifs et filtres de sécurité

Objectif de la section : Examiner les différentes stratégies d'unification de l'IA générative et des lois de commande sécuritaires afin de positionner la méthode de découplage retenue.

Pour allier l'expressivité et la multimodalité des modèles génératifs avec la rigueur des garanties de non-collision, deux grandes stratégies d'unification se distinguent dans la littérature : l'intégration des contraintes directement au cœur du processus de génération, ou l'application d'un filtre de sécurité en aval lors de l'exécution de la trajectoire.

2.5.1 Contraintes intégrées à la génération

La première stratégie injecte la contrainte de sécurité au sein même du processus d'intégration de l'équation différentielle (guidage intra-ODE). Par exemple, SafeFlow de Dai et al. [94] formule des fonctions barrières adaptées au *Flow Matching* afin de confiner le flux de trajectoires dans l'espace libre sans nécessiter de réentraînement du réseau. Dans la même ligne, SafeFlowMatcher [95] propose un intégrateur de type prédiction-correction certifié pour converger en temps fini vers la zone sûre. De son côté, CASF (Constrained Action Streaming Flows) de Long et al. [96] déforme localement la métrique riemannienne de l'espace de commande pour rejeter les trajectoires s'approchant des frontières d'obstacles. D'autres variantes récentes adaptent ces concepts sous forme de contraintes de Lyapunov ou de barrières stochastiques intégrées aux processus de diffusion [97, 98], ou s'appuient sur des optimisations unifiées pour garantir l'admissibilité dynamique des mouvements [99–101].

Cependant, bien qu'efficaces en simulation, ces méthodes intra-génération se heurtent à une limite structurelle majeure : la dérive distributionnelle (*distributional drift*). En forçant le processus d'intégration à traverser des états latents qui s'écartent de la distribution des données expertes vue à l'entraînement, ces contraintes perturbent la dynamique interne du modèle. Par conséquent, elles peuvent dégrader la qualité globale du mouvement généré et diminuer le taux de succès sur la tâche [102]. De surcroît, le coût computationnel d'une résolution de contraintes répétée à chaque étape d'intégration limite fortement leur utilisation pour du contrôle réactif en boucle fermée.

2.5.2 Filtres de sécurité appliqués à l'exécution

Pour préserver l'intégrité du modèle génératif, la seconde stratégie maintient la phase de génération nominale totalement inchangée et n'applique les contraintes de sécurité qu'en aval, lors de la commande physique du robot. L'archétype de ce paradigme est le cadre PACS (*Path-Consistent Safety filtering*) proposé par Römer et al. [102] pour les politiques de diffusion. Plutôt que de déformer géométriquement les actions générées, PACS convertit chaque bloc d'actions en une trajectoire d'intention, puis applique un freinage cohérent avec le chemin (*path-consistent braking*) : le robot est ralenti ou arrêté le long de cette trajectoire, dont la sécurité est certifiée en temps réel par une analyse d'atteignabilité ensembliste. Ce filtrage externe maintient l'exécution dans la distribution d'entraînement de la politique et fournit des garanties formelles de sécurité en environnement dynamique, en supposant toutefois des mesures de position des objets à erreur bornée. Les auteurs montrent qu'à l'inverse, un filtre réactif naïf de type CBF appliqué à l'effecteur pousse la politique hors de sa distribution d'entraînement, avec des taux de réussite inférieurs allant jusqu'à 68 % en simulation et 37 % sur plateforme réelle. Cette cohérence au chemin restreint cependant la correction au seul freinage : face à un obstacle qui bloque durablement la trajectoire nominale, le robot s'immobilise sans pouvoir le contourner, et les auteurs identifient eux-mêmes la gestion des obstacles statiques ou quasi-statiques comme une perspective future. Ce constat motive une correction géométrique locale qui, lorsqu'elle doit s'écarter de la trajectoire nominale, cherche à en rester le plus proche possible afin de limiter la dérive distributionnelle.

Dans cette perspective, d'autres approches proposent d'appliquer des corrections locales réactives (comme FlowCorrect [103]) pour adapter à la volée les trajectoires nominales à partir de signaux sporadiques, résolvant des cas d'échecs complexes sans réentraîner le réseau. Enfin, des filtres temporels spécifiques permettent également de compenser les délais d'inférence inhérents aux grands modèles génératifs [104, 105].

2.5.3 Découplage entre intention nominale et sécurité réactive

L'analyse croisée de ces deux familles d'approches justifie l'architecture découplée mise en œuvre dans ce travail. Plutôt que d'entrelacer la sécurité et la génération nominale, nous optons pour une isolation fonctionnelle complète entre :

1. **Un planificateur global en boucle ouverte** basé sur le *Flow Matching*, chargé de générer l'intention nominale à long terme sans subir de dérive distributionnelle.
2. **Un filtre de sécurité réactif local** basé sur une projection QP-CBF, s'exécutant à haute fréquence en ligne pour intercepter les collisions physiques sur le robot.

Ce découplage fonctionnel concilie efficacement la richesse et la multimodalité des trajectoires apprises par le modèle génératif avec la réactivité et la rigueur théorique indispensables pour améliorer la sécurité physique sur une plateforme réelle. Ce principe de séparation constitue le fil conducteur de la méthodologie proposée dans ce mémoire.

2.6 Synthèse critique et positionnement

Objectif de la section : Résumer les lacunes de l'état de l'art, formaliser l'hypothèse de recherche et présenter un tableau comparatif synthétique des architectures de la littérature.

2.6.1 Lacunes identifiées dans la littérature

L'analyse croisée de la littérature scientifique contemporaine met en évidence trois lacunes majeures :

1. **L'hypothèse d'une perception parfaite :** La plupart des cadres de travail actuels validant l'alliance du *Flow Matching* et des CBF supposent des obstacles analytiques parfaits connus a priori, se montrant ainsi inadaptés face aux nuages de points 3D bruts et bruités.
2. **L'absence de persistance temporelle des modèles génératifs :** Lors d'une occlusion temporaire de la cible, les planificateurs génératifs perdent leur signal de conditionnement géométrique et produisent des trajectoires aberrantes ou figées, faute d'une couche cartographique persistante capable de stabiliser les points de conditionnement.
3. **Le coût numérique des représentations globales :** Les approches basées sur la mise à jour de champs de distance globaux ou de *Neural SDF* s'avèrent trop lourdes pour soutenir une boucle de rétroaction à la fréquence de commande réactive face à des obstacles imprévus.

2.6.2 Positionnement de l'architecture proposée

Pour répondre à ces limites, ce mémoire soutient la pertinence d'une *architecture découplée entre génération nominale et filtrage réactif de sécurité*. La trajectoire nominale est générée en boucle ouverte par un modèle *Flow Matching* conditionné par une observation géométrique persistante issue de la perception RGB-D et du suivi SAM2, tandis que la sécurité immédiate est déléguée à un filtre de projection CBF articulaire bas niveau s'appuyant sur une approximation polynomiale de Bernstein du SDF local du robot.

2.6.3 Hypothèse de recherche

L'hypothèse centrale de cette recherche s'énonce ainsi :

« L'utilisation d'un filtre SDF-CBF fondé sur un SDF local du robot, approximé par des polynômes de Bernstein et alimenté par une carte perceptuelle persistante, permet de corriger en temps réel les vitesses nominales générées par un modèle *Flow Matching*, afin d'améliorer l'exécution sécuritaire de trajectoires dans des environnements quasi-statiques, non structurés et inconnus, mesurée par le taux de réussite de la tâche, la distance minimale de séparation aux obstacles et la durée des violations de la marge de sécurité, sans réentraîner le modèle génératif ni construire un champ de distance global de l'environnement. »

Le Tableau 2.1 résume le positionnement de l'approche proposée vis-à-vis des cadres de référence de la littérature. Les critères de comparaison s'y lisent comme suit : le modèle nominal désigne la politique générative produisant l'intention de mouvement ; la sécurité qualifie la nature du mécanisme d'évitement (implicite lorsqu'elle est seulement apprise des démonstrations, souple lorsqu'elle guide la génération sans imposer de contrainte, explicite lorsqu'une contrainte est imposée à l'exécution, formelle lorsqu'elle est certifiée mathématiquement) ; la représentation précise la forme sous laquelle les obstacles sont fournis au mécanisme de sécurité ; la correction décrit comment la sortie nominale est modifiée ; la colonne occlusions indique si le conditionnement perceptif résiste à une perte temporaire de visibilité ; enfin, la réactivité évalue la capacité à réagir à un changement de scène à la fréquence de commande.

En somme, l'examen critique de la littérature scientifique met en évidence un compromis entre l'expressivité des politiques génératives et la rigueur des algorithmes de préservation de la sécurité. Si le *Flow Matching* lissant et déterministe permet de capturer efficacement la multimodalité des mouvements experts tout en réduisant la latence propre aux processus de diffusion stochastique, son exécution en boucle ouverte au sein d'environnements réels et changeants demeure sujette aux incertitudes perceptives. Les méthodes contemporaines tentant d'incorporer des contraintes au cours de la phase de génération tendent à alourdir le temps de calcul ou à provoquer une dérive distributionnelle nuisible pour le succès de la tâche. Afin d'apporter une solution pragmatique à ces verrous technologiques, le Chapitre 4 détaillera la méthodologie de l'architecture découplée proposée dans ce travail. Nous y exposerons comment une architecture de perception persistante s'articule de manière synchrone avec un filtre réactif basé sur une approximation par polynômes de Bernstein pour améliorer, en temps réel et sous des contraintes vérifiables localement, l'exécution sécurisée définie au cœur de notre hypothèse de recherche.

Tableau 2.1 Tableau comparatif des frameworks de planification et de sécurité de l'état de l'art.

Cadre / Méthode	Modèle nominal	Sécurité	Représentation	Correction	Occlusions	Réactivité
Diffusion Policy	Diffusion	Implicite	Espace latent	Replanification en horizon fuyant, sans filtre de sécurité	Non	Limitée par le débruitage
OmniGuide	Flow Matching	Souple	Grille / énergie	Guidage intra-ODE	Non	Moyenne
CASF	Streaming Flow	Souple	Neural SDF	Déformation intra-ODE	Partielle	Élevée mais coûteuse
SafeFlow-Matcher	Flow Matching	Explicite CBF	Obstacles analytiques	Correction intra-génération	Non	Élevée en simulation
PACS	Diffusion	Formelle : atteignabilité ensembliste	Objets suivis, erreur bornée	Freinage sur la trajectoire nominale, sans contournement	Non	Très élevée (1 kHz)
Notre approche	Flow Matching	Explicite : projection SDF-CBF	Nuage filtré persistant + SDF robot	Correction vitesse articulaire à l'exécution	Oui, via persistance	Élevée, mesurée expérimentalement